




# 系统工程原理与方法



## 第六讲、系统优化 (上)

彭勤科

系统工程研究所


E-mail: [qkpeng@xjtu.edu.cn](mailto:qkpeng@xjtu.edu.cn)

Tel: 82667964

2020年5月30日



# 系统优化概述




- 在系统工程学科中的地位
- 最优化模型举例
- 优化模型的特点
- 最优化问题的基本概念
- 凸集和凸函数
- 优化模型分类
- 典型的优化问题
- 算法设计与分析




# 聚类-无监督学习

无导师学习



问题：把类标未知的数据按照一定目标分成不同的类。不同的目标函数产生了不同的聚类算法。以K-Means为例：  
确定K个聚类中心，使得每个数据点到聚类中心的平方和最小。但是约束条件是，每一个点只能属于其中一个聚类中心。


$$\left\{ \begin{array}{l} \min \sum_{n=1}^N \sum_{k=1}^K \gamma_{nk} \|x_n - \mu_k\|^2 \\ s.t. \sum_{k=1}^K \gamma_{nk} = 1, n \in \{1, 2, \dots, N\} \\ \gamma_{nk} \in \{0, 1\}. \end{array} \right.$$





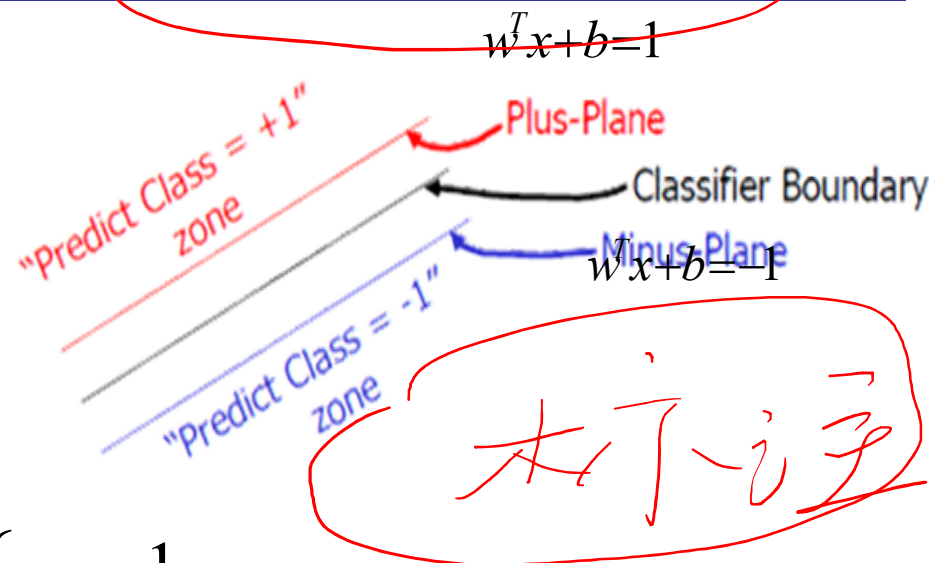
# 分类-有监督学习

有监督学习



问题：根据标注类别的数据建立分类模型，对未知类别的数据进行分类。不同建模方法导致不同的分类算法。以支持向量机(SVM)为例：


思路：构建最优的分类(超)平面，使得使得这个(超)平面尽可能将已知数据分开。但是约束条件是，已知的所属关系不能变。



$$\begin{cases} \min \frac{1}{2} \|w\|^2 \\ \text{s.t. } y_n (w^T x_n + b) \geq 1, n \in \{1, 2, \dots, N\} \\ y_n \in \{-1, 1\}, n \in \{1, 2, \dots, N\} \end{cases}$$



# 系统可靠性问题



问题：对 $N$ 个部件串联而成的系统，一部件出现故障时整个系统就不能正常工作，为每个部件配有备用件以提高可靠性，**在总费用一定的条件下**，如何配置备用件的数量才能使得**系统的可靠性最高**？


设第 $n$ 个部件配备 $u_n$ 个备件时，其正常工作的概率为 $P_n(u_n)$ ，第 $n$ 个备件的单价为 $c_n$ ，总经费为 $C$ 。



$$\begin{cases} \max & \prod_{n=1}^N P_n(u_n) \\ s.t. & \sum_{n=1}^N c_n u_n \leq C, \\ & u_n \geq 0, n \in \{1, 2, \dots, N\}. \end{cases}$$




# 资源分配问题(两种资源)




问题：资源总量分别是 $m_1$ 和 $m_2$ 的两种资源，分别给 $N$ 个用户，给第 $n$ 个用户分配资源的总量分别为 $u_n$ 和 $v_n$ 时产生的收益为 $g_n(u_n, v_n)$ ，如何分配资源使得收益最大？

$$\left\{ \begin{array}{l} \max \quad \sum_{n=1}^N g_n(u_n, v_n) \\ s.t. \quad \sum_{n=1}^N u_n = m_1, \\ \quad \quad \sum_{n=1}^N v_n = m_2. \\ \quad \quad 0 \leq u_n \leq m_1, 0 \leq v_n \leq m_2 \end{array} \right.$$






# 最小二乘参数估计



问题：根据若干样本（观测值），建立回归模型  $Y = X\beta + e$ ，使  $Y$  尽可能接近真实值。为此，可以从不同角度去确定建立样本回归函数的准则函数，也就有了估计回归模型参数的多种方法。我们以最小二乘法为例，**残差平方和最小**。（无约束优化模型）




最小二乘的几何解释：理论上响应变量  $Y$ ，与观测变量  $X$  系数  $\beta$  是一致的，但在实际应用中噪声和测量误差的存在，使得  $Y$  与  $X\beta$  存在偏差  $e$ 。

$$\min J = \sum_{n=1}^N e^2(n) = \mathbf{e}^T \mathbf{e} = (Y - X\beta)^T (Y - X\beta)$$

$$\left. \frac{\partial J}{\partial \beta} \right|_{\beta=\hat{\beta}} = -2X^T Y + 2X^T X \hat{\beta} = 0 \Rightarrow \hat{\beta} = (X^T X)^{-1} X^T Y$$



# 时间序列形态表示




问题：对时间序列进行形态表示（时域上降维）

给定时间序列：  $Q = \{q_1, q_2, \dots, q_n\}$ , 求  $Q^m = \{q_{t_1}, q_{t_2}, \dots, q_{t_m}\}$

优化模型：


$$\begin{aligned} \min_{Q^m} f(Q^m) &= \text{DTW}(Q, Q^m) \\ \text{s.t. } &\begin{cases} Q^m \subseteq Q \\ t_i < t_j, \forall 1 \leq i < j \leq m \end{cases} \end{aligned}$$







# 词语搬运距离




描述：对于计算两个文档之间的距离：用 $d$ 和 $d'$ 表示两个文档的 $nBOW$ 向量，允许 $d$ 中的任意一个词 $i$ 转移到 $d'$ 中的任意一个词 $j$ ，转移的代价是 $c(i, j)$ 。定义一个转移矩阵 $T \in R^{n \times n}$ ，其中 $T_{ij}$ 表示单词 $i$ 有多少的权重要转移到单词 $j$ 。

为了保证 $d$ 全部转移到 $d'$ ，必须满足 $\sum_{i=1}^n T_{ij} = d_i$ ， $d'$ 同理


问题：如何找到一个单词匹配方式，使得累加带权重求和距离最小？这个最小距离就是最终两个文本的相似度

$$\begin{aligned} \min_{T \geq 0} & \sum_{i,j=1}^n T_{ij} c(i, j) \\ \text{s. t.} & \sum_{j=1}^n T_{ij} = d_i \quad \forall i \in \{1, \dots, n\} \\ & \sum_{i=1}^n T_{ij} = d'_j \quad \forall j \in \{1, \dots, n\} \end{aligned}$$





# 对抗生成网络




通过生成网络**G**和判别网络**D**不断博弈，进而使**G**学习到数据的分布，从而达到生成数据的目的。

利用一个判别器去衡量生成的数据和真实数据之间的差距（**KL**散度），然后不断优化判别器和生成器，最终的平衡点即纳什均衡点。

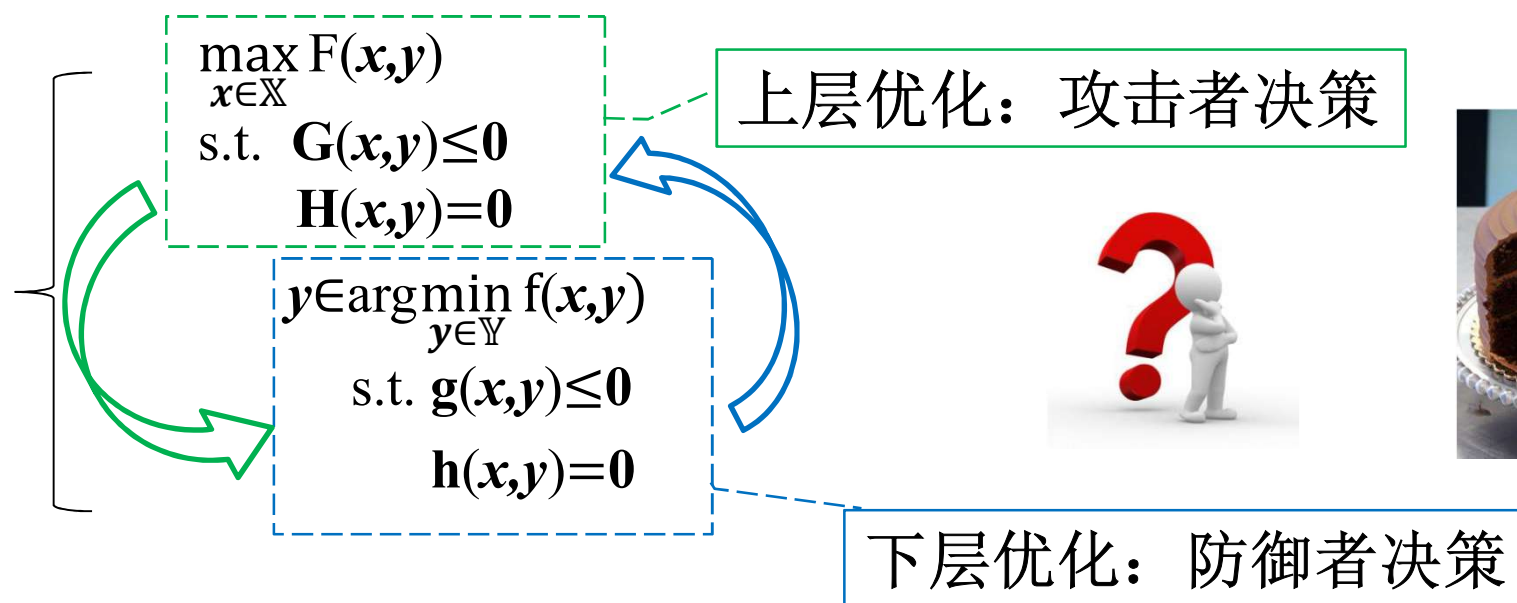
$$\begin{aligned}\theta^* &= \arg \max_{\theta} \prod_{i=1}^m p_G(x^i; \theta) = \arg \max_{\theta} \log \prod_{i=1}^m p_G(x^i; \theta) \\ &= \arg \max_{\theta} \sum_{i=1}^m \log p_G(x^i; \theta) \\ &\approx \arg \max_{\theta} E_{x \sim p_{data}} [\log p_G(x; \theta)] \\ &= \arg \max_{\theta} \int_x p_{data}(x) \log p_G(x; \theta) dx - \int_x p_{data}(x) \log p_{data}(x) dx \\ &= \arg \min_{\theta} KL(p_{data} \parallel p_G)\end{aligned}$$




# 安全攻防-双层优化



问题：安全攻防博弈过程是一类双层优化问题，其中，（上层）攻击者和（下层）防御者各自决策，交替作用，相互对抗，最终达到各自期望收益的最优值，实现纳什均衡。一般地，双层优化问题形如：





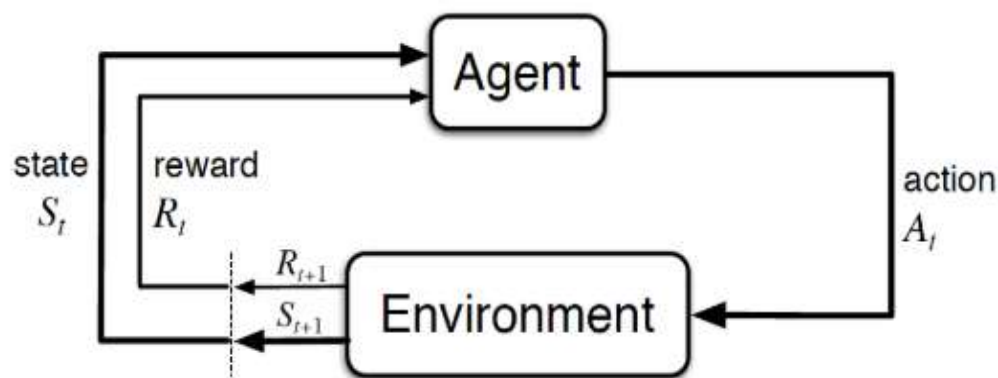
强化学习研究的是智能体与环境之间交互的任务。让智能体通过试错，不断地学习在不同的状态下做出最优的动作，即获得最大的未来回报的期望值，从而学习出最优策略。

优化目标：

$$\pi_* = \underset{\pi}{\operatorname{argmax}} V_{\pi}(s)$$


$V_{\pi}(s)$ : 状态 $s$ 时，使用策略 $\pi$ 时，未来回报的期望值。

$\pi_*$ : 最优策略





# 食谱问题



- 问题提出

设市场上可以买到  $n$  种不同的食品，第  $j$  种食品的价格为  $c_j$ ，每种食品含有  $m$  种营养成分，每单位第  $j$  种食品含第  $i$  种营养成分为  $a_{ij}$ 。假设每人每天对第  $i$  种营养成分的需要量不少于  $b_i$ ，试确定在保证营养条件下的最经济食谱。

- 模型建立

设每人每天对  $n$  种食品的需要量为： $x_1, x_2, \dots, x_n$ ，则相应的伙食费为：

$$c_1x_1 + c_2x_2 + \dots + c_nx_n$$


保证满足营养最小的需求约束方程为：

$$a_{i1}x_1 + a_{i2}x_2 + \dots + a_{in}x_n \geq b_i \quad i = 1, 2, \dots, m$$

$$x_j \geq 0 \quad j = 1, 2, \dots, n$$



# 食谱问题（续）



则数学模型为：  $\min \quad c_1x_1 + c_2x_2 + \cdots + c_nx_n$

$$s.t \quad a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n \geq b_1$$

$$a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n \geq b_2$$

.....

$$a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n \geq b_m \quad x_j \geq 0 \quad j = 1, 2, \cdots, n$$


如果令  $x = (x_1, x_2, \cdots, x_n)^T$      $c = (c_1, c_2, \cdots, c_n)$      $A = (a_{ij})_{m \times n}$      $b = (b_1, b_2, \cdots, b_m)^T$

则上面的优化模型可以写成如下矩阵形式：

$$\begin{aligned} &\min \quad cx \\ &s.t \quad Ax \geq b, x \geq 0 \end{aligned}$$




# 结构设计问题



## ● 问题提出


设两杆组成的对称桁架如下图所示，已知桁架的跨度为  $2L$ ，高度  $x_2$  的上限为  $H$ ，承受负荷  $2P$ ，钢管的厚度为  $T$ ，材料比重  $\rho$ ，纵向弹性系数为  $E$  且允许应力  $\sigma_y$ ，试确定钢管的平均内径  $x_1$  和桁架高度  $x_2$  并使桁架重量最小。







# 结构设计问题(续1)



## ● 模型建立

桁架的重量为:  $G = 2\pi\rho T x_1 (L^2 + x_2^2)^{1/2}$

高度约束:  $x_2 \leq H$

钢管压应力约束: 在负荷  $2P$  的作用下, 钢管承受的压力  $F$  为

$$F = \frac{P}{\cos \theta} = \frac{P(L^2 + x_2^2)^{1/2}}{x_2}$$

钢管的横截面面积  $S$  为  $S = \pi T x_1$


因此, 钢管的压应力为  $\sigma(x_1, x_2) = \frac{P(L^2 + x_2^2)^{1/2}}{\pi T x_1 x_2}$

所以对给定的允许应力  $\sigma_y$ , 要求  $\frac{P(L^2 + x_2^2)^{1/2}}{\pi T x_1 x_2} \leq \sigma_y$





# 结构设计问题(续2)



临界应力约束: 假设弹性模数为  $E$ , 则利用欧拉公式可以算出临界应力  $\sigma_l$  为


$$\sigma_l = \frac{\pi^2 E(x_1^2 + T^2)}{8(L^2 + x_2^2)} \quad \text{因此, 要求} \quad \frac{P(L^2 + x_2^2)^{1/2}}{\pi T x_1 x_2} \leq \frac{\pi^2 E(x_1^2 + T^2)}{8(L^2 + x_2^2)}$$

综上所述, 桁架设计问题的最优化模型为

$$\begin{aligned} \min \quad & 2\pi\rho T x_1 (L^2 + x_2^2)^{1/2} \\ \text{s.t.} \quad & x_2 \leq H \\ & \frac{P(L^2 + x_2^2)^{1/2}}{\pi T x_1 x_2} \leq \sigma_y \\ & \frac{P(L^2 + x_2^2)^{1/2}}{\pi T x_1 x_2} \leq \frac{\pi^2 E(x_1^2 + T^2)}{8(L^2 + x_2^2)} \\ & x_1 \geq 0, x_2 \geq 0 \end{aligned}$$



# 水果采购问题



- 问题提出

某单位举行联欢会要采购香蕉、苹果和葡萄，假设市场上香蕉、苹果和葡萄的价格分别为 4.2 元/公斤、2.4 元/公斤、2.2 元/公斤，如果要求采购水果的钱不超过 300 元、水果总重量不小于 10 公斤、香蕉和苹果总和不小于 6 公斤，试确定最好的采购方案。

- 模型建立


设  $x_1$ 、 $x_2$ 、 $x_3$  分别是购买香蕉、苹果和葡萄的重量（公斤），则购买水果的总金额  $y_1$  和采购水果的总重量  $y_2$  为

$$y_1 = 4.2x_1 + 2.4x_2 + 2.2x_3$$

$$y_2 = x_1 + x_2 + x_3$$



# 水果采购问题(续)



采购应该满足的约束为：

资金约束：  $4.2x_1 + 2.4x_2 + 2.2x_3 \leq 300$

重量约束：  $x_1 + x_2 + x_3 \geq 10$ ，  $x_1 + x_2 \geq 6$

非负约束：  $x_i \geq 0$ ，  $i = 1, 2, 3$

所以，优化模型为

$$\min 4.2x_1 + 2.4x_2 + 2.2x_3$$

$$\max x_1 + x_2 + x_3$$

$$s.t \quad 4.2x_1 + 2.4x_2 + 2.2x_3 \leq 300$$


$$x_1 + x_2 + x_3 \geq 10$$

$$x_1 + x_2 \geq 6$$

$$x_i \geq 0, \quad i = 1, 2, 3$$



# 优化模型的特点



- 优化模型的要素：目标、优化变量、约束集合  $(F(x), x, S)$

- ▣ 目标：用于度量优劣程度的指标（函数）

(1)  $\min c_1x_1 + c_2x_2 + \cdots + c_nx_n$

(2)  $\min 2\pi\rho Tx_1(L^2 + x_2^2)^{1/2}$

(3)  $\min 4.2x_1 + 2.4x_2 + 2.2x_3$   
 $\max x_1 + x_2 + x_3$

- ▣ 变量：表示优化的方案。

(1) 每人每天对  $n$  种食品的需要量  $x_1, x_2, \cdots, x_n$

(2) 钢管的平均厚度  $x_1$  和桁架高度  $x_2$


(3) 购买香蕉、苹果和葡萄的重量  $x_1$ 、 $x_2$ 、 $x_3$

- ▣ 约束集合：可行方案组成的集合。

由一组线性或非线性方程的等式或不等式组成。



# 最优化问题的基本概念



在优化问题的三要素  $(F(x), x, S)$  中，满足约束条件（在约束集合中）的点  $x$  称为可行点，全体可行点组成的集合  $S$  称为可行集或可行域或约束集合。如果一个优化问题没有包含约束集合  $S$ ，的可行集是整个空间，则称此问题为无约束问题。

设  $f(x)$  为目标函数， $x$  为优化变量， $S$  为可行集，极小化问题记为

$$\begin{aligned} \min f(x) & \quad (4.1) \\ \text{s.t. } x & \in S \end{aligned}$$


定义 4.1 对极小化问题 (4.1)， $\bar{x} \in S$ ，若对  $\forall x \in S$ ，有

$$f(x) \geq f(\bar{x})$$

则  $\bar{x}$  称为极小化问题 (4.1) 的最优解或极小解（整体最优解或全局最优解）



# 最优化问题的基本概念(续1)



定义 4.2 对极小化问题 (4.1),  $\bar{x} \in S$ , 若存在  $\bar{x}$  的  $\varepsilon (>0)$  邻域


$$N_\varepsilon(\bar{x}) = \{x \mid \|x - \bar{x}\| < \varepsilon, \varepsilon > 0\}$$

对  $\forall x \in S \cap N_\varepsilon(\bar{x})$ , 有

$$f(x) \geq f(\bar{x})$$

则  $\bar{x}$  称为极小化问题 (4.1) 的局部最优解或局部极小解。


注 1: 局部最优解在全局可能是很差的, 如下图  $\{\min f(x) \mid a \leq x \leq b\}$








# 凸集和凸函数




- 凸集概念与性质



- 凸函数概念与性质


$$f(\lambda x^1 + (1-\lambda)x^2) \leq \lambda f(x^1) + (1-\lambda)f(x^2)$$



凸函数的几何解说（弓弦在弓背上）



# 凸的优化问题的性质



- 凸优化问题

$f(x)$  是凸函数,  $S$  是凸集合

- 凸优化问题最优解的性质

- 凸优化问题如果存在局部最优解, 则该局部最优解必然为全局最优解。
- 对凸优化问题, 全局最优解容易计算。


- 非凸优化问题最优解的性质

- 局部最优解一般不是全局最优解。
- 对非凸优化问题, 由于大多数优化算法只能保证得到局部最优解, 所以全局最优解的计算需要在算法设计上进行特殊的考虑。






# 优化问题的分类



- 目标函数的数量
  - ▣ 单目标优化
  - ▣ 多目标优化
- 目标函数和约束函数的性质
  - ▣ 线性优化
  - ▣ 非线性优化
- 优化变量对时间的依赖性
  - ▣ 静态优化
  - ▣ 动态优化
- 优化变量定义域
  - ▣ 连续优化
  - ▣ 离散优化



# 典型的优化问题 - 线性规划



## ● 标准形式

$$\begin{aligned} \min \quad & \sum_{j=1}^n c_j x_j \\ \text{s.t.} \quad & \sum_{j=1}^n a_{ij} x_j = b_i \quad i=1,2,\dots,m \\ & x_j \geq 0, \quad j=1,2,\dots,n \end{aligned} \quad (7.1)$$


## 矩阵标准形式

$$\begin{aligned} \min \quad & cx \\ \text{s.t.} \quad & Ax = b \\ & x \geq 0 \end{aligned}$$

其中  $A = (a_{ij})_{m \times n}$  为  $m \times n$  矩阵,  $x$  是  $n$  维列向量,  $c$  是  $n$  维行向量,  $b$  是  $m$  维列向量。




# 线性规划问题的基本性质




- 基本概念：可行解、基本可行解、最优基本可行解，对偶定理，灵敏度分析，...
- 基本性质：线性规划问题的最优解必然在基本可行解（一般为有限个上）达到。

几何解释






# 线性规划的基本求解算法



- 标准单纯形法
- 修正单纯形法
- 对偶单纯形法
- 分解算法
- **Karmarkar**算法
- 内点算法



# 典型的优化问题 – 非线性规划



## 标准形式

无约束优化问题:


$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & x \in E^n \end{aligned} \quad (7.2)$$

有约束优化问题:

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & g_i(x) \geq 0 \quad i = 1, 2, \dots, m \\ & h_j(x) = 0 \quad j = 1, 2, \dots, l \end{aligned} \quad (7.3)$$



# 非线性规划的基本性质



## 基本定义

对目标函数  $f(x)$ ，称  $\nabla f(x) = (\frac{\partial f(x)}{\partial x_1}, \frac{\partial f(x)}{\partial x_2}, \dots, \frac{\partial f(x)}{\partial x_n})^T$  为  $f(x)$  在  $x$  处的梯度，


称矩阵

$$\nabla^2 f(x) = \begin{bmatrix} \frac{\partial^2 f(x)}{\partial x_1^2} & \frac{\partial^2 f(x)}{\partial x_1 \partial x_2} & \dots & \frac{\partial^2 f(x)}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f(x)}{\partial x_2 \partial x_1} & \frac{\partial^2 f(x)}{\partial x_2^2} & \dots & \frac{\partial^2 f(x)}{\partial x_2 \partial x_n} \\ \dots & \dots & \dots & \dots \\ \frac{\partial^2 f(x)}{\partial x_n \partial x_1} & \frac{\partial^2 f(x)}{\partial x_n \partial x_2} & \dots & \frac{\partial^2 f(x)}{\partial x_n^2} \end{bmatrix}$$

为  $f(x)$  在  $x$  处的 **Hessian** 矩阵。



# 无约束优化最优性条件




性质 7.1 （一阶必要条件）设函数  $f(x)$  在  $\bar{x}$  可微，若  $\bar{x}$  是问题 (7.2) 的局部最优解，则梯度  $\nabla f(\bar{x}) = 0$

性质 7.2 （二阶必要条件）设函数  $f(x)$  在  $\bar{x}$  二次可微，若  $\bar{x}$  是问题 (7.2) 的局部最优解，则梯度  $\nabla f(\bar{x}) = 0$ ，且 **Hessian** 矩阵  $\nabla^2 f(\bar{x})$  是半正定的。

性质 7.3 （二阶充分条件）设函数  $f(x)$  在  $\bar{x}$  二次可微，若  $\nabla f(\bar{x}) = 0$ ，且 **Hessian** 矩阵  $\nabla^2 f(\bar{x})$  是正定的，则  $\bar{x}$  是局部极小解。



# 有约束优化最优性条件



对问题 (7.3), 定义 **Lagrange** 函数

$$L(x, w, v) = f(x) - \sum_{i=1}^m \omega_i g_i(x) - \sum_{j=1}^l v_j h_j(x)$$

性质 7.4 (一阶必要条件, **K-T** 必要条件) 在问题 (7.3) 中,  $\bar{x}$  是可行解,  $I = \{i \mid g_i(\bar{x}) = 0\}$ ,  $f(x)$  和  $g_i(x) (i \in I)$  在  $\bar{x}$  可微,  $g_i(x) (i \notin I)$  在  $\bar{x}$  连续,  $h_j(x) = 0$  ( $j = 1, 2, \dots, l$ ) 在  $\bar{x}$  连续可微, 向量集

$$\{\nabla g_i(\bar{x}), \nabla h_j(\bar{x}) \mid i \in I, j = 1, \dots, l\}$$


线性无关, 若  $\bar{x}$  是问题 (7.3) 的局部最优解, 则存在  $\omega_i (i = 1, \dots, m)$  和  $v_j (j = 1, \dots, l)$ , 使得

$$\begin{aligned} \nabla f(\bar{x}) - \sum_{i=1}^m \omega_i \nabla g_i(\bar{x}) - \sum_{j=1}^l v_j \nabla h_j(\bar{x}) &= 0 \\ \omega_i g_i(\bar{x}) &= 0, i = 1, \dots, m \\ \omega_i &\geq 0, i = 1, \dots, m \end{aligned}$$






# 非线性规划问题的求解算法



- 无约束优化问题求解算法
  - ▣ 一维搜索算法：
    - ⊙ **0.618法**（黄金分割法）
    - ⊙ **Fibonacci法**
    - ⊙ 函数逼近法（牛顿法）...
  - ▣ 最速下降法
  - ▣ 牛顿法
  - ▣ 共轭梯度法
  - ▣ 拟牛顿法
  - ▣ ●●● ●●● ●●●
- 有约束优化问题求解算法
  - ▣ 可行方向法
  - ▣ 梯度投影法
  - ▣ 割平面法
  - ▣ 惩罚函数法
  - ▣ ●●● ●●● ●●●



# 典型的优化问题 – 多目标优化



- 标准形式

$$\min \begin{bmatrix} f_1(x) \\ f_2(x) \\ \dots \\ f_k(x) \end{bmatrix}$$

$$s.t. \quad g_i(x) \geq 0 \quad i = 1, 2, \dots, m$$

$$h_j(x) = 0 \quad j = 1, 2, \dots, l$$


- 基本性质：最优解→非劣解→满意解

- 求解算法

- ▣ 加权法
- ▣ 效用函数法
- ▣ 交互式方法
- ▣ 决策支持系统



# 算法设计与分析简介



- 算法举例


最速下降法

$$x^{k+1} = x^k - \lambda_k \nabla f(x^k)$$


$$\lambda_k = \min_{\lambda \geq 0} f(x^k - \lambda \nabla f(x^k))$$

牛顿法

$$x^{k+1} = x^k - \nabla^2 f(x^k)^{-1} \nabla f(x^k)$$



# 算法举例(续)



## 共轭梯度法


- (1) 给定初始点  $x^{(1)}$ ，置  $k = 1$ ；
- (2) 计算梯度  $g_k = \nabla f(x^{(k)})$ ，若  $\|g_k\| = 0$ ，则停止计算，得点  $\bar{x} = x^{(k)}$ ；  
否则，进行下一步；
- (3) 构造搜索方向，令  $d^{(k)} = -g_k + \beta_{k-1}d^{(k-1)}$   
其中当  $k = 1$  时，取  $\beta_{k-1} = 0$ ，当  $k > 1$  时，利用下式计算  $\beta_{k-1}$

$$\beta_{k-1} = \frac{\|g_k\|^2}{\|g_{k-1}\|^2}$$

- (4) 令  $x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$  其中  $\lambda_k = -\frac{g_k^T d^{(k)}}{d^{(k)T} A d^{(k)}}$
- (5) 若  $k = n$ ，则令  $\bar{x} = x^{(k+1)}$ ，否则，置  $k := k + 1$ ，返回 (2)。



# 算法基本概念



根据上面实例分析可以看出，算法包含三个要素和环节：

- (1) 初始点  $x^{(0)}$  或  $x^{(1)}$ ；
- (2) 如何从点  $x^{(k)}$  得到点  $x^{(k+1)}$ ，往往  $x^{(k+1)}$  是  $x^{(k)}$  的函数或多个函数组成的复合函数
- (3) 算法终止条件，如  $\|g_k\| = 0$ 。

一般而言，优化算法往往是迭代算法：

$$x^0, x^1, x^2, \dots, x^k, x^{k+1}, \dots$$

其中


$$x^{k+1} = A(x^k)$$

或更一般

$$x^{k+1} \in A(x^k)$$



# 算法基本概念(续)



定义 8.1 (迭代算法) 算法  $A$  是一个如下形式的映射:

$$x^{k+1} = A(x^k) \text{ 或 } x^{k+1} \in A(x^k)$$

例子 1: 最速下降法是点集映射。

$$x^{k+1} = x^k - \lambda_k \nabla f(x^k) \quad \lambda_k = \min_{\lambda \geq 0} f(x^k - \lambda \nabla f(x^k))$$


例子 2: 牛顿法是一个函数。

$$x^{k+1} = x^k - \nabla^2 f(x^k)^{-1} \nabla f(x^k)$$

例子 3: 而共轭梯度法是一个复合函数。

$$x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)} \quad d^{(k)} = -g_k + \beta_{k-1} d^{(k-1)}$$

$$\beta_{k-1} = \frac{\|g_k\|^2}{\|g_{k-1}\|^2} \quad \lambda_k = -\frac{g_k^T d^{(k)}}{d^{(k)T} A d^{(k)}}$$



## (1) 映射 $A(x)$

算法设计的重点，前面列举了的单纯行算法、最速下降法、牛顿法和共轭梯度法，后续将看详细介绍相关算法。

## (2) 算法终止条件

当梯度充分小时  $|\nabla f(x^{(k)})| < \varepsilon$


当优化变量变化很小时  $\|x^{(k+1)} - x^{(k)}\| < \varepsilon$   $\frac{\|x^{(k+1)} - x^{(k)}\|}{\|x^{(k)}\|} < \varepsilon$

当目标函数值增长非常小时

$$|f(x^{(k)}) - f(x^{(k+1)})| < \varepsilon \quad \frac{|f(x^{(k)}) - f(x^{(k+1)})|}{|f(x^{(k)})|} < \varepsilon$$



# 算法分析



## (1) 收敛性分析

序列  $\{x^{(k)} : k = 1, 2, \dots\}$  的收敛性分析，高等数学知识。

## (2) 收敛速度分析

定义 5: 设序列  $\{r^{(k)}\}$  收敛于  $r^*$ ，满足

$$0 \leq \overline{\lim}_{k \rightarrow \infty} \frac{\|r^{(k+1)} - r^*\|}{\|r^{(k)} - r^*\|^p} = \beta < \infty$$


的非负数  $p$  的上确界称为序列  $\{r^{(k)}\}$  的收敛阶（或级）。若序列的收敛阶为  $p$ ，则称该序列是  $p$  阶收敛的。

当阶  $p=1$  且  $\beta < 1$ ，则称序列是以收敛比  $\beta$  线性收敛的；若  $p > 1$  或  $p=1, \beta=0$ ，则称序列是超线性收敛的。





# 收敛速度分析举例



例子 1: 序列  $\{a^k\}$ ,  $0 < a < 1$  是以收敛比  $a$  线性收敛的;


例子 2: 序列  $\{a^{(2k)}\}$ ,  $0 < |a| < 1$  是 2 阶收敛的;

例子 3: 最速下降法是线性收敛的;

例子 4: 牛顿法是 2 阶收敛的。




# 优化理论研究的主要内容、关键问题、主要方法



- 关键问题
  - 规模
  - 非线性
  - **NP**问题
- 主要方法
  - 大系统
  - 并行
  - 随机算法
  - 进化算法等



# 本讲需要掌握的重点知识



- 优化模型要素（特别是优化模型与决策模型、评价模型的区别），建立优化模型的方法。